

Franco Veggiani - 4k9

Integración de un LLM Open Source con Grafo de Conocimiento

Plan de Estudios – Ingeniería en Sistemas (UTN-FRM)

El dominio seleccionado para la integración entre un grafo de conocimiento y un modelo de lenguaje local es el Plan de Estudios de la carrera Ingeniería en Sistemas de Información perteneciente a la Universidad Tecnológica Nacional – Facultad Regional Mendoza (UTN-FRM).

Este dominio es adecuado para la experiencia presentada debido a que representa un conjunto de entidades académicas con relaciones claramente definidas, las cuales los estudiantes consultan con frecuencia utilizando expresiones en lenguaje natural. Entre las consultas típicas pueden encontrarse: prerequisites de asignaturas, competencias que desarrolla una materia, áreas temáticas y semestre recomendado de cursado.

Objetivo del modelado

El propósito del grafo es estructurar el conocimiento académico necesario para asistir a los estudiantes en la planificación de su trayectoria, permitiendo consultas que requieran atravesar relaciones múltiples y dependencias curriculares que serían difíciles de interpretar únicamente mediante tablas o documentos estáticos.

Entidades modeladas

El grafo contiene los siguientes tipos de nodos, cada uno con propiedades específicas:

Tipo de nodo	Ejemplo	Descripción
Course (Materia)	Minería de Datos, Sistemas Operativos	Representa una asignatura del plan de estudios
Area	Bases de Datos, Programación	Agrupar materias según su orientación temática
Skill (Competencia)	SQL, Programación Orientada a Objetos	Define saberes y capacidades que desarrolla una asignatura

Semester	1, 2, 3, 4	Identifica el período en el que se dicta una materia
Category	Unidad Curricular, Competencia	Permite clasificar los nodos dentro de categorías generales

Relaciones modeladas

Las relaciones del grafo reflejan dependencias y organización curricular:

Relación	Dirección	Significado académico
PREREQ	(Curso A) → (Curso B)	Indica que A debe aprobarse antes de cursar B
BELONGS_TO	(Curso) → (Área)	Determina la orientación temática de una materia
COVERS	(Curso) → (Competencia)	Detalla los conocimientos abordados
TAUGHT_IN	(Curso) → (Semester)	Indica el periodo de cursado recomendado
IS_A	(Nodo) → (Category)	Relación de clasificación conceptual

Vinculación con el modelo LLM

El grafo contiene información estructurada y verificable, mientras que el modelo de lenguaje permite interpretar consultas realizadas en español y generar respuestas comprensibles.

Esto funciona de la siguiente manera:

1. Se ha utilizado un modelo ideal para la generación de texto complejo, facilitado por la disposición de una GPU (1050 3GB), llamado llama3.2, que pesa 4GB y tiene una cantidad de 3B de parámetros.
2. Se ha creado el grafo de conocimientos en neo4j de manera local con Docker para hacer más sencillo este proceso.
3. Se ha creado un entorno en python (venv) para la instalación de librerías necesarias con pip y requirements.txt.
4. Se ha creado un archivo .py que define una consulta inicial para el modelo nombrado, dándole ejemplos y ordenando que no puede realizar consultas que modifiquen la estructura de la base de datos. Después de esto, se han definido otras

funciones que permiten extraer la consulta Cypher y ejecutarla en la base de datos, y también generar una respuesta mediante el modelo.

Los pasos lógicos de uso para este proyecto son

1. Realizar pregunta, ejemplo: ¿Qué cursos cubren SQL y Modelado ER?
2. El script en python recibe la pregunta, le hace saber al modelo el SCHEMA actual (modelo de conocimiento) y hace un *ollama run* con la consulta que escribió el usuario.
3. El modelo responde con la consulta Cypher ideada, y el script extrae la consulta.
4. El script ejecuta la consulta Cypher y obtiene el resultado.
5. El script vuelve a llamar al modelo, pasándole la respuesta. Finalmente el LLM genera la respuesta en NL y se muestra por consola.

```
>> ¿Qué cursos cubren SQL y Modelado ER?

● Pregunta: ¿Qué cursos cubren SQL y Modelado ER?

📄 Cypher generado:

MATCH (c:Course)-[:COVERS]->(s:Skill)
WHERE toLower(s.name) IN [toLower("SQL"), toLower("Modelado ER")]
RETURN c.code AS code, c.name AS course, collect(DISTINCT s.name) AS skills
ORDER BY course

📊 Resultado:
| code | course | skills |
|-----|-----|-----|
| IS-301 | Bases de Datos | ['SQL', 'Modelado ER'] |
| IS-402 | Minería de Datos | ['SQL'] |

🗨 Respuesta:
No hay resultados. El curso que cubre SQL y Modelado ER es el IS-301, pero no hay cursos que cubran ambos temas.
>> 
```

A continuación dejo una serie de preguntas de ejemplo para verificar su correcto funcionamiento.

```
>> ¿Qué materias tengo que aprobar antes de cursar Minería de Datos?

● Pregunta: ¿Qué materias tengo que aprobar antes de cursar Minería de Datos?

📄 Cypher generado:

MATCH (pre:Course)-[:PREREQ]->(c:Course {name: "Minería de Datos"})
RETURN pre.code AS code, pre.name AS name
ORDER BY name

📊 Resultado:
| code | name |
|-----|-----|
| IS-301 | Bases de Datos |
| IS-401 | Inteligencia Artificial |

🗨 Respuesta:
Para cursar Minería de Datos, debes aprobar las siguientes materias:

* Bases de Datos (IS-301)
* Inteligencia Artificial (IS-401)
>> 
```

```
>> ¿En qué semestre se dicta el cursado de Sistemas Operativos?
```

● Pregunta: ¿En qué semestre se dicta el cursado de Sistemas Operativos?

📄 Cypher generado:

```
MATCH (c:Course {name: "Sistemas Operativos"})-[:TAUGHT_IN]->(sm:Semester)
RETURN c.code AS code, c.name AS course, sm.num AS semester
```

📊 Resultado:

code	course	semester
IS-303	Sistemas Operativos	3

🔵 Respuesta:
No hay resultados. El curso "Sistemas Operativos" se dicta en el semestre 3, pero no hay información sobre si se dicta en otro semestre o no.

```
>> Mostrame cursos del área Bases de Datos y en qué semestre se dictan.
```

● Pregunta: Mostrame cursos del área Bases de Datos y en qué semestre se dictan.

📄 Cypher generado:

```
MATCH (c:Course)-[:BELONGS_TO]->(a:Area {name: "Bases de Datos"})
OPTIONAL MATCH (c)-[:TAUGHT_IN]->(sm:Semester)
RETURN c.code AS code, c.name AS course, a.name AS area, sm.num AS semester
ORDER BY semester, course
```

📊 Resultado:

code	course	area	semester
IS-301	Bases de Datos	Bases de Datos	2

🔵 Respuesta:
No hay resultados.

```
>>
```

Importante aclarar que a veces el modelo no es capaz de interpretar los resultados de la base de datos, esto es debido a que el modelo es pequeño, entonces tiene limitaciones a la hora de interpretar. Sin embargo, se observa que las consultas en cypher se realizan exitosamente, y los resultados son mostrados.

Conclusión

El Plan de Estudios de Ingeniería en Sistemas constituye un dominio adecuado para la construcción de un grafo de conocimiento debido a su complejidad relacional y su aplicación práctica inmediata. La integración con un modelo de lenguaje mejora la accesibilidad al conocimiento académico, permitiendo obtener información precisa y fundamentada mediante preguntas formuladas en lenguaje natural.

Código: <https://github.com/franveggiani/integracionLLMGrafoConocimiento>.